

HAI 评测实施计划

InCharacter / CharacterEval 适配与核心实验落地方案

可直接执行版本 | 评测设计 + 数据规模 + 脚本结构 + 时间表 + 验收门槛

项目	Emotion- and Gesture-Aware AI Chat Avatar (HAI)
仓库	xma688/HAI, main 分支
评测范围	用户画像、个性化回复、动作/语音规划、中文多轮对话、用户体验
版本日期	2026-07-15

核心决策

主评测不是“角色扮演忠实度”

HAI 的核心是根据用户画像改变回复、动作和语音策略。因此，CharacterEval 只保留相关中文对话指标；InCharacter 降为可选诊断；用户画像正确性、个性化反事实、Action Planner 和正式用户实验成为主线。

1. 一页执行摘要

本计划将原 PDF 的 “InCharacter + CharacterEval 双主 Benchmark” 改为分层评测。原因是当前 HAI 的 Big Five 表示用户画像，系统据此调整自己的交流方式；它并不是一个固定文学角色的扮演器。

评测项	最终定位	是否进入主结果表	执行结论
用户画像正确性	主评测	是	直接测试 ProfileManager 的 Big Five / 偏好推断
个性化反事实	主评测	是	同一输入只改变画像，验证方向性与无关字段稳定性
Action / Voice 规划	主评测	是	测试标签合法性、冲突纠正、动作强度、语速与跨轮稳定性
CharacterEval 子集	辅助评测	是（单独列）	仅报告相关维度，不报告删减后的官方 Overall Score
InCharacter	可选诊断	否或附录	仅定义固定 AvatarPersona 后正式使用；否则标记为 adapted
A/B/C 用户实验	系统级主评测	是	必须切换真实 pipeline；增加个性化消融

立即可执行的最小版本（MVP）

- 冻结一个仓库 commit、模型版本、系统 prompt、温度、seed、TTS 和配置文件；每次结果保存 config hash。
- 创建 11 个受控用户画像：中性基线 + Big Five 五个维度各自高/低。
- 创建 12 个多轮场景，每个 4 轮；每个画像运行 2 个 seed，共 264 段对话、1056 个模型回复。
- 建立 200 条 Action / Voice 金标准样本，至少两名标注者独立标注后仲裁。
- 从 CharacterEval 选取约 100 条中文多轮样本，仅计算流畅、连贯、跨轮一致、类人性、表达多样性和共情等相关维度。
- 完成 4 个个性化消融：关闭个性化、仅 Prompt、仅 PostProcessor、完整 HAI。
- Live2D 未接入前完成自动评测和小规模 pilot；正式 A/B/C 用户实验在真实 Avatar 和真实 pipeline 接入后进行。

最终应回答的四个研究问题

RQ	研究问题	主要证据
RQ1	系统能否正确建立用户画像？	Big Five MAE/相关性、偏好分类准确率、轮数-误差曲线
RQ2	画像是否真正改变了输出，而且改变方向合理？	反事实方向正确率、无关字段泄漏率、成对效应量
RQ3	动作、表情和语音参数是否合理、稳定并符合画像？	Macro-F1、冲突率、修正规则命中、跨轮抖动、参数单调性
RQ4	完整 HAI 是否提升真实用户体验？	个性化消融 + 模态 A/B/C 的问卷、偏好和行为指标

2. 评测对象与 Benchmark 边界

仓库当前三层结构包括基础 LLM/TTS/Avatar、Action Reasoning，以及 UserProfile 驱动的个性化层。README 显示完整 Mock 管线、真实 LLM、真实 TTS、个性化层和用户实验工具已实现，但真实 Live2D 渲染尚未接入。

HAI 分层评测框架

A. 用户画像正确性	ProfileManager 是否正确推断用户 Big Five / 偏好
B. 个性化反事实	同一问题改变画像，输出是否按预期变化且无无关泄漏
C. 中文对话质量	CharacterEval 相关维度：流畅、连贯、一致、共情
D. 动作与语音规划	ActionPlanner + PostProcessor 的标签、冲突、强度、语速
E. 系统用户实验	个性化消融 + 模态 A/B/C；正式实验禁用 Mock
F. InCharacter (可选)	仅在定义固定 AvatarPersona 后使用；否则只做 adapted 诊断 主线：A+B+D+E；辅助：C；可选：F

为什么不能直接把 InCharacter 当作主评测

- InCharacter 原本比较“目标角色人格”和“Agent 实际呈现的人格”。
- 当前 HAI 的 Big Five 是用户画像，PromptBuilder 使用该画像指导系统如何对待用户；高神经质用户应得到更 calm/supportive 的回复，并不表示 Avatar 本身是高神经质。
- 因此 InCharacter 可以诊断输出呈现的人格，但不能直接证明用户画像推断正确，也不能证明个性化策略正确。
- 只有新增独立的 AvatarPersona，并明确其目标 Big Five 后，InCharacter 才能作为正式角色人格评测。

CharacterEval 保留哪些、舍弃哪些

类别	处理	说明
流畅、连贯、跨轮一致	保留	直接评价中文多轮回复质量
类人性、沟通能力、表达多样性、共情	保留	与 HAI 的交互体验目标一致
Persona-Utterance / 语言风格	条件保留	需要先定义稳定的 Avatar 基础语气或当前条件画像
角色知识暴露/准确性/幻觉	舍弃	当前系统没有文学角色知识边界和角色知识库
MBTI Accuracy	舍弃	当前系统使用 Big Five，不应混为同一心理概念
Persona-Behavior	不直接等价	其文本行为标注不等于真实 AvatarCommand 的动作执行

命名规范

删减后的结果统一写作 “CharacterEval-derived dialogue metrics” 或 “CharacterEval relevant-dimension subset”。若改造 InCharacter，写作 “InCharacter-inspired adapted evaluation”。不得将它们包装为完整官方总分。

3. Phase 0 - 冻结环境与建立评测骨架（1-2 个工作日）

3.1 必须冻结的实验信息

- Git commit SHA、Python 版本、依赖锁文件、操作系统与硬件。
- LLM provider、模型名、API endpoint、system prompt 内容及 SHA-256。
- temperature、top_p、max_tokens、seed；无法真正固定 seed 的 API 要记录重复次数。
- PERSONALIZATION_ENABLED、Action Planner cooldown、max_gestures、PostProcessor 阈值。
- TTS provider、voice、rate、volume；Avatar provider 及是否为 Mock。
- 每个运行的 UTC 时间、延迟、异常、重试、fallback、warnings。

3.2 建议新增目录

```
evaluation/
  configs/
    eval_mvp.yaml
    eval_full.yaml
  datasets/
    persona_profiles.json
    scenarios.jsonl
    action_gold.jsonl
    character_eval_subset.jsonl
  runners/
    run_profile_eval.py
    run_counterfactual.py
    run_action_eval.py
    run_character_eval_subset.py
    run_ablation.py
  adapters/
    character_eval_adapter.py
  scorers/
    profile_metrics.py
    counterfactual_metrics.py
    action_metrics.py
    dialogue_metrics.py
  reports/
    build_report.py
  results/<run_id>/
    manifest.json
    outputs.jsonl
    metrics.json
    errors.jsonl
```

3.3 统一输出记录格式

字段	内容	用途
run_id	日期 + commit + 配置短哈希	可追踪一次完整实验
profile_id / scenario_id	受控画像与场景标识	支持成对反事实比较
condition	none / prompt / post / full	个性化消融
raw_llm_output	原始模型字符串	定位 JSON 解析和幻觉标签问题
reply_text	最终文本回复	CharacterEval 子集与文本指标
avatar_command_before/after	Planner 前后与 PostProcessor 后参数	归因修正来自哪个模块
warnings / fallback	校验警告与降级	计算非法标签率、fallback 率
latency_ms / token_usage	延迟与调用成本	系统效率和用户实验解释变量

3.4 Smoke Test 验收

- [] Mock provider 与真实 provider 各运行 5 个样本，输出 JSONL 可被 scorer 无错误读取。
- [] 同一输入在固定配置下可复现，或至少完整记录 API 非确定性。
- [] 原始输出、Planner 输出和 PostProcessor 输出均保存，禁止只保存最终结果。
- [] 所有结果文件含 manifest.json，缺失任何关键字段则评测停止。

4. Track A/B - 用户画像与个性化反事实（主评测）

4.1 受控用户画像设计

MVP 使用“单因素高/低”设计，避免多个维度同时变化导致归因不清。所有维度归一化到 [0,1]。

profile_id	变化项	建议值	其余 Big Five	主要预期
neutral	无	全部 0.50	0.50	基线
O_high / O_low	开放性	0.85 / 0.15	0.50	措辞丰富度与新颖性变化
C_high / C_low	尽责性	0.85 / 0.15	0.50	结构化、步骤化程度变化
E_high / E_low	外向性	0.85 / 0.15	0.50	动作频率、热情程度变化
A_high / A_low	宜人性	0.85 / 0.15	0.50	温和、鼓励、协作语气变化
N_high / N_low	神经质	0.85 / 0.15	0.50	calm/supportive、慢速和低强度变化

4.2 场景集合

类别	MVP 数量	示例目标	重点观察
情绪支持	3	压力、失败、焦虑	共情、语气、表情、速度
知识解释	3	解释概念、给步骤	结构化、清晰度、explain 动作

类别	MVP 数量	示例目标	重点观察
社交寒暄	2	初次见面、日常聊天	热情度、口语化、动作频率
决策建议	2	选择方案、规划任务	尽责性适配、条理性
边界/告别	2	拒绝、道歉、结束对话	small_bow/wave、礼貌与稳定性

4.3 两类测试必须分开

测试	输入方式	测什么	关键指标
A1 画像推断	从默认画像开始，输入带已知人格证据的用户语句	关键词更新是否方向正确、累积速度是否合理	维度 MAE、方向准确率、达到阈值所需轮数、误触发率
A2 自报告画像	直接 set_self_report 注入标准值	下游个性化模块能否正确使用理想画像	用于隔离 ProfileManager 误差
B 反事实适配	同一场景只替换 profile_id	输出是否按预期变化且保持内容任务正确	方向正确率、成对效应量、无关泄漏率、任务保持率

4.4 MVP 运行规模

推荐规模

11 个画像 × 12 个场景 × 2 个 seed = 264 段对话。每段 4 轮，共 1056 个模型回复。先用 Mock 完成管线测试，再用真实模型运行正式数据。

4.5 个性化消融

条件	PromptBuilder	PostProcessor	用途
P0 无个性化	关闭	关闭	基础 LLM / Planner 对照
P1 Prompt only	开启	关闭	文本和原始标签层适配
P2 Post only	关闭	开启	纯参数约束与动作过滤效果
P3 Full HAI	开启	开启	完整系统

4.6 主要指标与建议门槛

指标	定义	MVP 建议门槛
画像方向准确率	高/低证据是否让对应维度朝正确方向变化	$\geq 90\%$
无证据误触发率	不相关文本是否改变目标维度	$\leq 10\%$
反事实方向正确率	高/低画像的文本或参数变化是否符合预注册方向	$\geq 80\%$
无关字段泄漏率	只改变一个维度却显著改变不应变化的输出	$\leq 15\%$
任务保持率	个性化后仍完成原对话任务	$\geq 95\%$

指标	定义	MVP 建议门槛
重复稳定性	同画像多次运行的标签/参数一致性	Krippendorff alpha 或一致率 ≥ 0.75

注意：以上是工程 go/no-go 门槛，不是论文中预先保证的结果。正式论文需报告置信区间、效应量和所有失败样本，而不是只报告是否过线。

5. Track D - Action Planner 与语音参数评测（主评测）

5.1 金标准数据集

建立 200 条中文场景，每条包含用户输入、必要的对话历史和合理标签范围。不是要求唯一动作，而是允许一个可接受集合，以免把主观风格当成单一真值。

标注字段	标注形式	示例
emotion	单标签或可接受集合	supportive
expression	可接受集合	{soft_smile, concerned}
gestures	0-2 个动作集合 + 禁止动作	{nod}; 禁止 surprised
voice_style	单标签或集合	{calm, gentle}
gesture_intensity	区间	[0.20, 0.50]
speaking_rate	区间	[0.75, 1.00]
pause	区间或顺序等级	中等/较长
rationale	一句标注理由	用户焦虑，避免夸张动作和过快语速

5.2 标注流程

- 两名标注者独立标注；先完成 30 条 pilot，统一分歧定义后再标余下样本。
- 计算离散标签的一致率 / Cohen kappa；区间参数计算 ICC 或允许区间重叠率。
- 分歧由第三人仲裁，保留原始标注和仲裁结果。
- 标注者不可看到模型输出，避免形成模型依赖的金标准。

5.3 自动指标

维度	指标
标签正确性	Macro-F1、集合命中率、Exact Match（辅助）
参数合理性	区间命中率、MAE、单调性违例率
鲁棒性	非法标签率、JSON 修复率、fallback 率、warning 数量
规则价值	Planner 修正前后错误率差值；每条规则的 precision / coverage
跨轮稳定性	动作切换次数、重复动作冷却命中、情绪无依据突变率
个性化效果	PostProcessor 前后动作数、强度、语速的成对变化

5.4 对现有规则的专项单元测试

规则	测试样本	预期
supportive + surprised	焦虑/压力支持场景	expression 修正为 soft_smile
serious + smile	严肃提醒场景	expression 修正为 serious
apologetic	道歉场景	自动加入 small_bow
thoughtful + idle	思考型问题	自动加入 think
告别关键词	再见/拜拜/下次见	优先加入 wave
解释关键词	为什么/怎么/解释	优先加入 explain
gesture cooldown	短时间重复同动作	替换为 nod 或 idle 并记录 warning
低动作 affinity	画像中某动作 < 0.2	PostProcessor 过滤或替换

关键归因要求

每条样本必须同时保存：LLM 原始标签、ActionPlanner 后标签、PostProcessor 后标签。否则无法判断提升来自模型、规则校验还是用户画像约束。

6. Track C/F - CharacterEval 子集与 InCharacter 可选实验

6.1 CharacterEval 子集执行步骤

- 从官方数据中抽取约 100 条中文多轮对话，优先保留不依赖特定文学角色背景知识的样本。
- 写 character_eval_adapter.py，将 HAI 的 history / user_text / reply_text 转为评测器所需格式。
- 预注册保留维度：Fluency、Coherency、Conversation Consistency、Human-likeness、Communication Skills、Expression Diversity、Empathy。
- Persona-Utterance 只有在先定义 Avatar 基础语气或明确条件画像后才计算。
- 同一子集同时跑 P0-P3 四个消融，观察个性化是否提升体验但损害内容质量。
- 报告每项维度及 bootstrap 95% CI，不求一个混合 Overall Score。

6.2 CharacterEval 结果表模板

Condition	Fluency	Coherency	Consistency	Empathy	Human-like	Diversity
P0 None	-	-	-	-	-	-
P1 Prompt	-	-	-	-	-	-
P2 Post	-	-	-	-	-	-
P3 Full	-	-	-	-	-	-

6.3 InCharacter 的决策门

条件	处理
没有独立 AvatarPersona	不跑正式 InCharacter；最多在附录做 adapted 诊断

条件	处理
已定义 AvatarPersona Big Five，但系统仍根据用户适配	固定目标人格，分别对不同用户画像运行，测试基础人格是否被适配层冲掉
希望研究“系统对高/低用户画像的表达差异”	可借用心理访谈问题，但结果写作 adapted evaluation，不与官方角色分数直接比较

6.4 新增 AvatarPersona 后的最小设计

```
AvatarPersona:
  name: "HAI Companion"
  big_five:
    openness: 0.65
    conscientiousness: 0.70
    extraversion: 0.55
    agreeableness: 0.85
    neuroticism: 0.20
  invariant_style:
    - patient
    - supportive
    - non-judgmental

UserProfile:
  # 与 AvatarPersona 分离，只决定适配策略
  big_five: ...
  communication_preferences: ...
```

此时 InCharacter 的问题变为：系统在面对不同用户时能否调整策略，但仍保持 Avatar 自身温和、耐心、低神经质的基础人格。这个研究问题才与官方 benchmark 的角色人格忠实度接近。

7. Track E - 用户实验设计（系统级主评测）

7.1 先修条件

- 正式实验必须将 run_experiment.py 中的 build_mock_pipeline() 替换为真实 pipeline。
- 模式 C 必须有真实可观察的 Avatar 表情和动作；仅打印日志不能作为完整 Avatar 条件。
- 记录参与者看到的模型版本、语音、Avatar、响应延迟和个性化状态。
- 取得参与者同意；用户画像、自报告 Big Five 和对话日志分离保存并匿名化。

7.2 推荐两阶段用户实验

阶段	设计	目标	样本量建议
Pilot	6-8 人，观察流程与问卷理解	排查时长、失败、动作不自然、条件暴露	6-8
正式实验 A	同一模态下 P0 vs P3, within-subject、顺序平衡	证明个性化层的增益	至少 24-30
正式实验 B	Text vs Voice vs Voice+Avatar, within-或 mixed-design	证明多模态呈现增益	至少 30；最终用 power analysis 确定

7.3 条件与顺序控制

- 优先先做“个性化是否有效”，再做“模态是否有效”，避免一次实验中因素过多。
- within-subject 条件使用 Latin square 或随机平衡，防止学习和疲劳效应。
- 每个条件使用内容难度等价但文本不同的任务集，避免参与者重复看到同一回复。
- 参与者和分析者尽可能对条件名称盲法，不展示“个性化开启/关闭”。

7.4 问卷与行为指标

类别	指标
现有问卷	naturalness、engagement、human-like、gesture_match、latency_ok、overall
必须新增	被理解感、回复适合我、语气舒适、动作不过度、愿意继续使用、隐私担忧
行为指标	对话轮数、主动追问、提前退出、响应时长、重试/纠正次数
开放问题	哪一处最像/不像为你定制；哪些动作让你不舒服；是否感到被贴标签

7.5 统计分析

- Likert 数据报告中位数/IQR，同时可用累计链接混合模型或配对非参数检验。
- 报告效应量和 95% CI；多指标比较使用 Holm 校正。
- 把参与者作为随机效应；对话场景作为另一个随机效应或分层因素。
- 预先定义排除规则：系统故障、未完成条件、明显未认真填写。

8. 具体实施顺序与命令模板

8.1 Day 1-2：建立骨架并跑 Smoke

```
# 1. 在仓库根目录创建评测分支
git checkout -b eval/benchmark-v1

# 2. 记录当前环境
python --version > evaluation/results/env.txt
pip freeze >> evaluation/results/env.txt
git rev-parse HEAD > evaluation/results/commit.txt

# 3. 先跑现有测试
PYTHONPATH=src pytest

# 4. 运行评测 smoke
PYTHONPATH=src python evaluation/runners/run_counterfactual.py \
  --config evaluation/configs/eval_mvp.yaml --provider mock --limit 5
```

8.2 Day 3-5：准备数据与金标准

- 生成 persona_profiles.json 和 scenarios.jsonl。
- 写 200 条 action_gold 候选，先双标 30 条并修订指南。
- 筛选 CharacterEval 子集并记录每条样本保留/排除理由。
- 锁定 expected_direction.yaml：每个画像变化预期影响哪些文本和参数指标。

8.3 Day 6-8：跑四个消融

```
for condition in none prompt post full; do
  PYTHONPATH=src python evaluation/runners/run_ablation.py \
    --config evaluation/configs/eval_mvp.yaml \
    --condition $condition \
    --provider openai \
    --output evaluation/results/$condition
done

PYTHONPATH=src python evaluation/reports/build_report.py \
  --runs evaluation/results/none evaluation/results/prompt \
    evaluation/results/post evaluation/results/full \
  --out evaluation/results/mvp_report
```

8.4 Day 9-10：人工复核与失败分析

- 按指标最差的 10%、随机 10% 和规则修正样本全部人工复核。
- 建立 error taxonomy：画像误推断、过度个性化、无关泄漏、任务失败、标签冲突、跨轮抖动、fallback。
- 每类至少给出 3 个代表案例和代码层归因。

8.5 Week 3+：用户实验

- 接入真实 Avatar 后先跑 6-8 人 pilot。
- 根据 pilot 方差做 power analysis，再确定正式样本量。
- 完成注册/预注册、匿名 ID、顺序平衡、数据备份和问卷导出。

8.6 每阶段交付物

阶段	必须交付
P0 可复现	manifest、配置、环境、统一 JSONL、smoke log
P1 自动评测	264 段对话、四个消融、原始/Planner/Post 三阶段输出
P2 金标准	action_gold.jsonl、标注指南、一致性与仲裁记录
P3 Benchmark	CharacterEval 子集清单、adapter、逐维结果与 CI
P4 用户实验	protocol、consent、randomization、匿名数据、统计脚本
最终报告	主表、消融表、失败案例、限制、可复现实验命令

9. 推荐时间表与责任分工

时间	任务	负责人角色	完成定义
Day 1	冻结仓库、配置、数据 schema	开发	manifest + 目录 + smoke 可运行
Day 2	实现统一 runner / logger / scorer 接口	开发	Mock 和真实 provider 均输出统一 JSONL
Day 3-4	画像、场景、expected direction	研究设计	11 画像 + 12 场景 + 预注册方向
Day 4-6	Action 金标准 pilot 与指南	2 标注者 + 仲裁者	30 条 pilot 一致性达标后继续
Day 6-8	跑 P0-P3 自动实验	实验执行	264 段/条件完成，无缺失
Day 8-9	CharacterEval 子集与 adapter	开发 + 研究设计	约 100 条逐维结果
Day 9-10	失败分析与 MVP 报告	全体	主表 + 案例 + go/no-go
Week 3	接入真实 Avatar、用户实验 pilot	系统 + HCI	6-8 人流程无重大故障
Week 4+	正式用户实验与最终报告	HCI + 统计	预注册分析与匿名数据完成

先（源不足）

优先级	必须做	可延后
P0	统一 logging、反事实个性化、Planner/PostProcessor 三阶段输出	任何外部 benchmark
P1	Action 金标准、四个消融、CharacterEval 相关维度	完整 CharacterEval
P2	真实 pipeline 用户 pilot	大规模用户实验
P3	独立 AvatarPersona 后的 InCharacter	当前立即运行 InCharacter

预算粗估

资源	MVP
LLM 调用	约 1056 回复 × 4 个消融；可先对 P0/P3 全量，P1/P2 缩小为 50%
人工标注	200 条 × 2 人；预计每条 1-2 分钟 + 仲裁
研究人员	1 名开发 + 1 名实验设计；标注可由 2-3 人兼职
用户实验	先 6-8 人 pilot；正式样本量由 pilot 方差和 power analysis 决定

10. Go/No-Go 验收表与风险控制

10.1 自动评测上线门槛

检查项	Go 条件	No-Go 后动作
数据完整性	所有样本含 manifest、raw、三阶段 command	修 runner；不得补写猜测值
结构化输出	解析成功率 $\geq 99\%$ ，fallback 可追踪	修 prompt/parser，重跑受影响样本
画像测试	方向准确率和误触发率达到预设门槛	修改关键词权重或降低论文主张
反事实测试	大多数预注册方向成立，任务保持率不下降	定位 Prompt 或 PostProcessor 的副作用
Action 金标准	标注一致性达标，模型指标可稳定复现	修标注指南与标签定义
Benchmark 命名	子集明确标为 derived / adapted	禁止报告误导性官方总分

10.2 用户实验上线门槛

- [] 真实 pipeline 和真实 Avatar 可稳定完成 10 次连续对话，无明显崩溃。
- [] 平均延迟处于可接受范围，且每条对话均记录延迟。
- [] 所有条件只有实验因素不同，模型、内容难度、设备和界面保持一致。
- [] 同意书、退出机制、匿名化和数据删除流程已经准备。
- [] pilot 没有发现参与者无法理解问卷或明显猜到条件。

10.3 主要风险

风险	影响	缓解措施
关键词画像过于脆弱	画像准确率低，个性化结论不成立	分开报告自报告画像与自动推断画像；将推断模块作为独立限制
基础 LLM 主导结果	误把模型能力当成 HAI 创新	固定模型，做 P0-P3 消融，保存三阶段输出
外部评测器偏差	CharacterEval 自动评分不稳定	抽样人工复核，报告 evaluator 版本与一致性
过度个性化/贴标签	用户感到冒犯或不适	增加隐私与被贴标签问卷；设置最小变化和安全边界
Mock 用户实验	结论缺乏生态有效性	Mock 仅用于工程 smoke，不进入正式结果
动作无唯一真值	Exact Match 低估合理输出	使用可接受集合、区间和人评，不依赖单一标签

论文主张边界

MVP 通过后可以主张“HAI 的个性化层能产生方向合理、可测量的文本和非语言行为差异”。只有在真实 Avatar 用户实验完成后，才能进一步主张“这些差异提升了用户体验”。

11. 开始执行前的最终 Checklist

序号	任务	状态
1	创建 eval/benchmark-v1 分支并记录 commit SHA	[]
2	创建 evaluation/ 目录和统一 JSONL schema	[]
3	定义 11 个画像和 12 个场景	[]
4	写 expected_direction.yaml 并冻结	[]
5	实现 P0-P3 四个消融开关	[]
6	保存 raw / Planner / PostProcessor 三阶段输出	[]
7	建立 200 条 Action 金标准及标注指南	[]
8	筛选 CharacterEval 相关子集并写 adapter	[]
9	跑 264 段 MVP 对话并生成主表	[]
10	人工复核失败样本并建立 error taxonomy	[]
11	真实 Avatar 接入后再跑 A/B/C 用户实验	[]
12	只有定义 AvatarPersona 后再决定是否跑 InCharacter	[]

建议的最终报告结构

- Table 1: 画像推断准确性。
- Table 2: P0-P3 个性化反事实结果。
- Table 3: Action / Voice 金标准指标与规则贡献。
- Table 4: CharacterEval-derived 中文对话维度。
- Table 5: 用户实验个性化与模态条件。
- Figure 1: 不同画像下动作强度、动作数、语速的成对变化。
- Figure 2: 随交互轮数增长的用户画像误差。
- Appendix: InCharacter adapted 结果、失败案例、完整 prompt 和配置。

参考与依据

[R1] HAI repository and implementation: <https://github.com/xma688/HAI>

[R2] HAI personalization / planner modules: https://github.com/xma688/HAI/tree/main/src/hai_avatar

[R3] HAI user experiment runner: https://github.com/xma688/HAI/blob/main/scripts/run_experiment.py

[R4] InCharacter project: <https://incharacter.github.io/>

[R5] CharacterEval repository: <https://github.com/morecry/CharacterEval>

[R6] 用户提供的 INCHARACTER_CHARACTEREVAL_BRIEF.pdf: 本地上传文件，作为原始评测方案