

HAI 评测方案：InCharacter + CharacterEval

结论

主要关注两件事：

1. Avatar 是否稳定表现出设定的人格；
2. 多轮对话中，角色的语言风格和行为是否前后一致。

因此选定InCharacter 和 CharacterEval 作为当前阶段的两项主要 Benchmark。

这两个 Benchmark 主要评估角色人格与角色一致性。

1. InCharacter：人格特征是否真实、稳定

论文：[InCharacter: Evaluating Role-Playing Agents Through Psychological Interviews](#)

项目主页：<https://incharacter.github.io/>

代码：[GitHub Repository](#)

原始任务

InCharacter 不让角色直接选择“我是外向还是内向”，而是让 Agent 接受开放式心理访谈。评测器根据多轮回答，推断角色在 Big Five 等人格维度上的表现，再与目标人格画像进行比较。

主要评估内容

- 角色是否表现出目标人格；
- 人格特征是否能在自然回答中体现；
- 多次访谈后人格表现是否稳定；
- Agent 是否只是复述角色设定，而是真正表现出相应行为倾向。

对 HAI 的价值

InCharacter 可以用于检查：

- Big Five 画像是否被正确注入；
- 高外向、低外向等不同画像是否产生预期的回答差异；
- 人格画像是否在多轮对话中保持一致；
- 即时情绪是否被错误地当成稳定人格。

来源

InCharacter 论文发表于 ACL 2024 Main，项目页、题库和代码公开，方法具有明确的心理量表依据。质量评为 5/5。

2. CharacterEval：中文多轮角色对话是否一致

论文：[CharacterEval: A Chinese Benchmark for Role-Playing Conversation Evaluation](#)

代码：<https://github.com/morecry/CharacterEval>

原始任务

CharacterEval 面向中文角色扮演对话，包含多个角色、多轮对话和较大规模的评测样本。它重点检查角色在连续对话中的一致性，而不是只看某一轮回答是否合理。

主要评估内容

- 角色是否遵循既定人物设定；
- 角色的语言风格是否稳定；
- 前后回答是否出现人格冲突；
- 多轮对话中是否发生角色漂移；
- 中文语境下的角色表现是否自然。

对 HAI 的价值

CharacterEval 可以用于检查：

- 中文对话中的角色一致性；
- 角色语气、表达习惯和行为倾向是否稳定；
- 不同对话主题下是否仍然保持同一人格；
- 长对话过程中是否逐渐偏离原始设定。

来源判断

CharacterEval 论文发表于 ACL 2024 Main，数据规模、中文场景和代码公开情况都比较完整。质量评为 5/5。

3. 两个 Benchmark 的关系

这两个 Benchmark 是从不同角度测同一个角色：

评测角度	InCharacter	CharacterEval
核心问题	人格特征是否真实	角色对话是否一致
主要方法	心理访谈 + 人格量表	中文多轮角色对话
重点指标	Big Five 人格维度、人格稳定性	角色设定遵循、语言风格、跨轮一致性
适合发现的问题	人格画像错误、人格表现不稳定	角色漂移、前后矛盾、风格不一致
HAI 中的作用	人格层主评测	对话层主评测

可以将两者概括为：

InCharacter 检查“这个角色到底表现出了什么人格”；CharacterEval 检查“这个角色在连续中文对话中有没有保持住这种人格”。

4. 对 HAI 研究需求的覆盖

HAI 评测需求	覆盖情况	说明
Persona / Big Five 表现	InCharacter 直接覆盖	有心理量表和访谈流程
角色设定遵循	CharacterEval 直接覆盖	关注中文多轮角色一致性
中文语言风格稳定性	CharacterEval 直接覆盖	适合多轮对话
人格跨轮稳定性	两者共同覆盖	一个偏人格量表，一个偏对话行为
用户历史利用	两者均不直接覆盖	需要额外做用户历史对照
个性化行为差异	两者均不直接覆盖	需要额外做反事实画像实验
动作、TTS、口型	当前不在范围内	本阶段不评估

5. 个性化部分的补充实验

如果后续需要证明 HAI 能够根据不同用户产生合理差异，可以在两个 Benchmark 之外增加最小对照实验：

- 同一问题 + 高外向画像；
- 同一问题 + 低外向画像；
- 同一问题 + 相关用户历史；
- 同一问题 + 无关用户历史。

主要观察：目标人格或偏好相关的输出是否发生预期变化，以及无关字段是否保持稳定。这个实验属于 HAI 的个性化评估，不应写成 InCharacter 或 CharacterEval 的官方分数。

6. 链接汇总

- [InCharacter 论文](#)
- [InCharacter 项目主页](#)
- [InCharacter 代码](#)
- [CharacterEval 论文](#)
- [CharacterEval 代码](#)

